

Guia de Ollama

Para AI Dungeon Master

Instalacion, configuracion y uso del motor de IA local

Version 1.0 · 2025 · <https://ollama.com>

1. Que es Ollama

Ollama es una aplicacion gratuita que te permite correr modelos de inteligencia artificial directamente en tu PC, sin necesidad de internet ni pagar por una API. Es el motor que usa AI Dungeon Master para generar la narracion del juego.

Ventajas de Ollama

- * Completamente gratuito — sin suscripciones ni API keys
- * Funciona sin internet — todo corre en tu PC
- * Privado — tus conversaciones no salen de tu computadora
- * Compatible con Windows, macOS y Linux
- * Soporta docenas de modelos de IA diferentes

2. Instalacion en Windows

1. Abre tu navegador y ve a: **<https://ollama.com/download>**
2. Haz clic en **Download for Windows** — se descargara un archivo .exe
3. Ejecuta el instalador y sigue los pasos (siguiente, siguiente, instalar)
4. Al terminar, Ollama se inicia automaticamente en segundo plano
5. Veras el icono de Ollama en la barra de tareas (esquina inferior derecha)

OK Para verificar que Ollama esta corriendo, abre tu navegador y ve a <http://localhost:11434> — debe mostrar el texto 'Ollama is running'.

3. Descargar el Modelo de IA

Ollama necesita un **modelo** para funcionar — es el cerebro que genera el texto. Para AI Dungeon Master recomendamos **llama3.2:1b** por ser rapido y ligero.

Paso a paso

6. Abre una terminal: presiona **Windows + R**, escribe `cmd` y presiona Enter
7. Escribe el siguiente comando y presiona Enter:

```
ollama pull llama3.2:1b
```

8. Espera a que termine la descarga — veras una barra de progreso (~1 GB)
9. Cuando diga `success`, el modelo esta listo
10. Verifica que se descargo correctamente con:

```
ollama list
```

Deberas ver `llama3.2:1b` en la lista.

Comparacion de modelos disponibles

Modelo	Tamaño	Velocidad	Recomendado para
llama3.2:1b	~1 GB	Muy rapido	PCs basicas, laptop
llama3.2	~2 GB	Rapido	PCs con 8GB+ RAM
llama3	~4 GB	Moderado	PCs con GPU dedicada
mistral	~4 GB	Moderado	Alternativa a llama3
gemma2:2b	~1.6 GB	Rapido	Alternativa ligera de Google

Para cambiar de modelo en el juego, edita la línea 8 de `ai_master.py` con el nombre del modelo que descargaste.

4. Como se Conecta con el Juego

Ollama funciona como un servidor local en tu PC. Cuando el juego necesita generar texto, le manda una petición a Ollama y este responde con la narración del Dungeon Master.

AI Dungeon Master (main.py)	Ollama (servidor local)
Detecta gesto de mano	—
Calcula accion (dado, dano, etc.)	—
Envia peticion a localhost:11434	Recibe la peticion
—	Genera la narracion con llama3.2:1b
Recibe el texto generado	Envia respuesta
Muestra la narracion en pantalla	—

! Ollama DEBE estar corriendo antes de ejecutar python main.py. Si lo cierras, el juego mostrara 'Error: Ollama no esta corriendo'.

5. Comandos Utiles de Ollama

Comando	Que hace
<code>ollama pull llama3.2:1b</code>	Descarga el modelo llama3.2:1b
<code>ollama list</code>	Muestra los modelos descargados
<code>ollama run llama3.2:1b</code>	Prueba el modelo en la terminal
<code>ollama serve</code>	Inicia el servidor (normalmente automatico)
<code>ollama rm llama3.2:1b</code>	Elimina un modelo descargado
<code>ollama ps</code>	Muestra modelos activos en memoria

6. Problemas Comunes

Error: 'Only one usage of each socket address'

Significa que Ollama **ya esta corriendo**. No necesitas hacer nada — es una buena noticia.

Error: 'timed out' en el juego

El modelo tarda demasiado en responder. Soluciones:

- * **Usa llama3.2:1b** — es el mas rapido: `ollama pull llama3.2:1b`
- * Cierra otras aplicaciones pesadas mientras juegas
- * Aumenta el timeout en ai_master.py linea con 'timeout=120' a 'timeout=180'

Error: 'connection refused'

Ollama no esta corriendo. Abre la aplicacion de Ollama desde el menu de inicio de Windows.

El modelo no aparece en 'ollama list'

La descarga no se completo. Vuelve a ejecutar: `ollama pull llama3.2:1b`

7. Checklist Antes de Jugar

	Verificacion	Como comprobar
[]	Ollama instalado	Icono en barra de tareas o app abierta
[]	Ollama corriendo	http://localhost:11434 dice 'Ollama is running'
[]	Modelo descargado	ollama list muestra llama3.2:1b
[]	Librerias Python instaladas	pip install -r requirements.txt sin errores
[]	Camara conectada y funcionando	Se ve imagen en la ventana del juego

OK Cuando todos los puntos esten marcados, ejecuta 'python main.py' y disfruta el juego.